



УНИВЕРЗИТЕТ У НОВОМ САДУ
ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА У
НОВОМ САДУ



Борис Летић

Анализа сентимента крипто заједнице на друштвеним мрежама помоћу машинског учења

ДИПЛОМСКИ РАД
- Основне академске студије -

Нови Сад, 2025.



КЉУЧНА ДОКУМЕНТАЦИЈСКА ИНФОРМАЦИЈА

Редни број, РБР:			
Идентификациони број, ИБР:			
Тип документације, ТД:	Монографска документација		
Тип записа, ТЗ:	Текстуални штампани материјал		
Врста рада, ВР:	Дипломски рад		
Аутор, АУ:	Борис Летић		
Ментор, МН:	др Душан Гајић, ванредни професор		
Наслов рада, НР:	Анализа сентимента крипто заједнице на друштвеним мрежама помоћу машинског учења		
Језик публикације, ЈП:	Српски		
Језик извода, ЈИ:	Српски		
Земља публикација, ЗП:	Република Србија		
Уже географско подручје, УГП:	АП Војводина		
Година, ГО:	2025.		
Издавач, ИЗ:	Ауторски репринт		
Место и адреса, МА:	Нови Сад, Трг Доситеја Обрадовића 6		
Физички опис рада, ФО: (поглавља/страна/цитата/табела/слика/графика/прилога)	5/33/10/9/3/0/0		
Научна област, НО:	Електротехника и рачунарство		
Научна дисциплина, НД:	Примењене рачунарске науке и информатика		
Предметна одредница/Кључне речи, ПО:	Машинско учење, крипто заједница, друштвена мрежа		
УДК			
Чува се, ЧУ:	Библиотека Факултета техничких наука, Нови Сад		
Важна напомена, ВН:			
Извод, ИЗ:	Овај рад описује систем за аутоматску класификацију сентимента Twitter корисника о Bitcoin-у користећи технике машинског учења. Имплементирана су три различита приступа: Naive Bayes као baseline модел, Support Vector Machine (SVM) са RBF kernel-ом, и BERT transformer модел заснован на дубоком учењу. Систем користи Python 3.11, PyTorch, scikit-learn и NLTK за обраду природног језика. SVM модел постиже највишу тачност од 95.24%, док корелациона анализа показује да Twitter сентимент прати Bitcoin цену са временским кашњењем од 6 дана ($r=0.226$, $p=0.024$), што указује да сентимент не може предвидети будуће промене цене, већ реагује на њих.		
Датум прихватања теме, ДП:			
Датум одбране, ДО:			
Чланови комисије, КО:	Председник:	др Вељко Петровић, доцент	Потпис ментора
	Члан:	др Дину Драган, редовни професор	
	Члан, ментор:	др Душан Гајић, ванредни професор	



UNIVERSITY OF NOVI SAD & FACULTY OF TECHNICAL SCIENCES

21000 NOVI SAD, Trg Dositeja Obradovića 6

KEY WORDS DOCUMENTATION

Accession number, ANO :		
Identification number, INO :		
Document type, DT :	Monographic publication	
Type of record, TR :	Textual printed material	
Contents code, CC :	Bachelor Thesis	
Author, AU :	Boris Letić	
Mentor, MN :	Dušan Gajić, PhD, Associate Professor	
Title, TI :	Sentiment Analysis of a Crypto Community on Social Networks Using Machine Learning	
Language of text, LT :	Serbian	
Language of abstract, LA :	Serbian	
Country of publication, CP :	Republic of Serbia	
Locality of publication, LP :	AP Vojvodina	
Publication year, PY :	2025	
Publisher, PB :	Author's reprint	
Publication place, PP :	Novi Sad, Trg Dositeja Obradovića 6	
Physical description, PD : (chapters/pages/ref./tables/pictures/graphs/appendixes)	5/33/10/9/3/0/0	
Scientific field, SF :	Electrical and Computer Engineering	
Scientific discipline, SD :	Applied Computer Science and Informatics	
Subject/Key words, S/KW :	Machine Learning, Crypto Community, Social Network	
UC		
Holding data, HD :	The Library of the Faculty of Technical Sciences, Novi Sad	
Note, N :		
Abstract, AB :	This thesis describes a system for automatic sentiment classification of Twitter users regarding Bitcoin using machine learning techniques. Three different approaches were implemented: Naive Bayes as a baseline model, Support Vector Machine (SVM) with an RBF kernel, and BERT transformer model based on deep learning. The system uses Python 3.11, PyTorch, scikit-learn, and NLTK for natural language processing. The SVM model achieves the highest accuracy of 95.24%, while correlation analysis shows that Twitter sentiment follows Bitcoin price with a 6-day time lag ($r=0.226$, $p=0.024$), indicating that sentiment cannot predict future price changes but rather reacts to them.	
Accepted by the Scientific Board on, ASB :		
Defended on, DE :		
Defended Board, DB :	President:	Veljko Petrović, PhD, Assistant Professor
	Member:	Dinu Dragan, PhD, Full Professor
	Member, Mentor:	Dušan Gajić, PhD, Associate Professor
		Mentor's sign

	УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА	Датум:
	21000 НОВИ САД, Трг Доситеја Обрадовића 6	
	ЗАДАТАК ЗА ИЗРАДУ ДИПЛОМСКОГ (BACHELOR) РАДА	Лист/Листова:
		/

(Податке уноси предметни наставник - ментор)

Врста студија:	☒ Основне академске студије ☐ Основне струковне студије
Студијски програм:	Рачунарство и аутоматика
Руководилац студијског програма:	проф. др Иван Каштелан

Студент:	Борис Летић	Број индекса:	РА 207/2021
Област:	Електротехничко и рачунарско инжењерство		
Ментор:	др Душан Гајић, ванредни професор		

НА ОСНОВУ ПОДНЕТЕ ПРИЈАВЕ, ПРИЛОЖЕНЕ ДОКУМЕНТАЦИЈЕ И ОДРЕДБИ СТАТУТА ФАКУЛТЕТА ИЗДАЈЕ СЕ ЗАДАТАК ЗА ДИПЛОМСКИ (Bachelor) РАД, СА СЛЕДЕЋИМ ЕЛЕМЕНТИМА:

- проблем – тема рада;
- начин решавања проблема и начин практичне провере резултата рада, ако је таква провера неопходна;
- литература

НАСЛОВ ДИПЛОМСКОГ (BACHELOR) РАДА:

АНАЛИЗА СЕНТИМЕНТА КРИПТО ЗАЈЕДНИЦЕ НА ДРУШТВЕНИМ МРЕЖАМА ПОМОЋУ МАШИНСКОГ УЧЕЊА

ТЕКСТ ЗАДАТКА:

▪ Упознати се са техникама машинског учења и анализе сентимента. ▪ Имплементирати и евалуирати изабране моделе машинског учења за класификацију сентимента Twitter порука о Bitcoin блокчејну. ▪ Упоредити класичне приступе (наивни Бајесов, SVM) са савременим приступом заснованим на дубоком учењу (BERT). ▪ Анализирати статистичку повезаност између Twitter сентимента и цене Bitcoin-а. ▪ Утврдити временску динамику везе сентимент-цена кроз lag анализу и извести одговарајуће закључке.

Руководилац студијског програма:	Ментор рада:

Примерак за: ☐ - Студента; ☐ - Ментора



УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА
21000 НОВИ САД, Трг Доситеја Обрадовића 6

ИЗЈАВА О НЕПОСТОЈАЊУ СУКОБА ИНТЕРЕСА

Изјављујем да нисам у сукобу интереса у односу ментор – кандидат и да нисам члан породице (супружник или ванбрачни партнер, родитељ или усвојитељ, дете или усвојеник), повезано лице (крвни сродник ментора/кандидата у правој линији, односно у побочној линији закључно са другим степеном сродства, као ни физичко лице које се према другим основама и околностима може оправдано сматрати интересно повезаним са ментором или кандидатом), односно да нисам зависан/на од ментора/кандидата, да не постоје околности које би могле да утичу на моју непристрасност, нити да стичем било какве користи или погодности за себе или друго лице било позитивним или негативним исходом, као и да немам приватни интерес који утиче, може да утиче или изгледа као да утиче на однос ментор-кандидат.

У Новом Саду, дана _____

Ментор

Кандидат

САДРЖАЈ

1.	Увод.....	7
1.1	Мотивација	7
1.2	Циљ рада.....	7
2.	Теоријске основе	8
2.1	Анализа сентимента	8
2.2	Обрада природног језика.....	9
2.3	Модел машинског учења	10
2.4	Коришћене технологије	12
3.	Архитектура и дизајн система.....	13
3.1	Општа архитектура система	13
3.2	Скуп података	13
3.3	Дизајн модула претпроцесирања.....	13
3.4	Детаљан опис корака	14
3.5	Дизајн модела	16
4.	Имплементација и резултати.....	17
4.1	Имплементација модела.....	17
4.2	Резултати класификације	18
4.3	Корелациона анализа.....	22
4.4	Поређење са сродним истраживањима	24
4.5	Дискусија.....	25
5.	Закључак.....	28
5.1	Резиме истраживања	28
5.2	Одговори на истраживачка питања	29
5.3	Ограничења истраживања	29
5.4	Будући рад	30
5.5	Практична примена	30
5.6	Теоријски допринос.....	31
5.7	Финална разматрања	31
	Литература.....	32
	Биографија.....	33

1. Увод

Развој друштвених мрежа у последњој деценији створио је огромне количине неструктурираних текстуалних података који садрже драгоцене информације о јавном мишљењу и емоцијама корисника. Twitter, као једна од водећих платформи за микроблоговање, омогућава корисницима да у реалном времену изражавају своје ставове о различитим темама, укључујући финансијска тржишта и криптовалуте.

Bitcoin, као најпознатија криптовалута, привлачи значајну пажњу на друштвеним мрежама, са милионима објава дневно. Анализа сентимента ових објава може пружити увид у колективно расположење инвеститора и трговаца, што представља вредан инпут за доношење финансијских одлука.

1.1 Мотивација

Традиционални приступ анализи јавног мишљења заснива се на анкетама и фокус групама, што је временски захтевно, скупо и често субјективно. Са друге стране, друштвене мреже нуде непрекидан ток информација које корисници добровољно деле, чинећи их идеалним извором података за аутоматску анализу сентимента.

Неколико студија показало је потенцијалну везу између сентимента на друштвеним мрежама и кретања финансијских тржишта. Међутим, примена ових техника на тржиште криптовалута остаје релативно неистражена област.

1.2 Циљ рада

Главни циљеви овог дипломског рада су:

- Имплементација и евалуација различитих модела машинског учења за класификацију сентимента Twitter порука о Bitcoin-у
- Поређење класичних приступа (Naive Bayes, SVM) са савременим deep learning приступом (BERT)
- Анализа статистичке повезаности између Twitter сентимента и цене Bitcoin-а
- Утврђивање временске динамике везе сентимент-цена кроз lag анализу

2. Теоријске основе

2.1 Анализа сентимента

Анализа сентимента (енгл. sentiment analysis), позната и као рударење ставова или мишљења (енгл. opinion mining), је област обраде природног језика (енгл. natural language processing - NLP) која се бави аутоматском детекцијом, екстракцијом и квантификацијом субјективности, емоција и мишљења у текстуалним подацима. Њен циљ је да из неструктурираног текста идентификује ауторову емоционалну оријентацију према одређеној теми.

Нивои анализе сентимента

Анализа сентимента може се спроводити на различитим нивоима:

- Ниво документа - класификује цео документ као позитиван, негативан или неутралан
- Ниво реченице -- анализира сентимент на нивоу појединачних реченица
- Ниво аспекта -- идентификује сентимент према специфичним аспектима

У овом раду фокусирамо се на анализу на нивоу документа, где сваки твит (енгл. tweet) третирамо као самосталан документ.

Приступи анализи сентимента

Постоје три главна приступа анализе сентимента:

- Засновано на речнику -- заснива се на претходно дефинисаним речницима сентимент речи
- Машинско учење -- користи супервизовано учење на анотираним подацима (Naive Bayes, SVM)
- Дубоко учење -- користи неуронске мреже које аутоматски уче репрезентације текста (BERT)

2.2 Обрада природног језика

Обрада природног језика (NLP) је интердисциплинарна област која комбинује лингвистику, рачунарство и вештачку интелигенцију како би омогућила рачунарима да разумеју, интерпретирају и генеришу људски језик.

Предобрада текста

Претпроцесирање је критичан корак у NLP проточном систему који трансформише сирови текст у структуран формат погодан за машинску обраду.

Токенизација

Токенизација је процес дељења текста на мање јединице зване токени (речи, знаци интерпункције, бројеви). За енглески језик, NLTK библиотека пружа робустан tokenizer који рукује са различитим граматичким конструкцијама.

Текст: „Bitcoin is going to the moon!“

Токени: [„Bitcoin“, „is“, „going“, „to“, „the“, „moon“, „!“]

Нормализација

Нормализација обухвата неколико техника:

- Lowercase -- Конверзија свих слова у мала слова
- Stop words removal -- Уклањање често коришћених речи („is“, „the“, „to“)
- Stemming -- Редукција речи на корене (нпр. „running“ → „run“)
- Lemmatization -- Софистициранија форма нормализације која користи морфолошку анализу

Издајање карактеристика

Након претпроцесирања, текст мора бити конвертован у нумеричке векторе које ML модели могу да процесирају.

TF-IDF

Учесталост термина - инверзна учесталост документа (енгл. Term Frequency-Inverse Document Frequency) је статистичка мера која евалуира важност речи у документу у контексту корпуса.

$$TF(t, d) = \frac{\text{број појављивања термина } t \text{ у документу } d}{\text{укупан број термина у } d}$$

$$IDF(t, D) = \log \frac{|D|}{|\{d \in D : t \in d\}|}$$

$$TF - IDF(t, d, D) = TF(t, d) \times IDF(t, D)$$

где је D скуп свих докумената, d појединачни документ, и t термин.

TF-IDF даје већу тежину речима које су честе у документу али ретке у корпусу, што их чини дискриминативним карактеристикама.

N-grams

N-grams су секвенце од n узастопних речи. Користимо:

- Unigrams ($n=1$): појединачне речи
- Bigrams ($n=2$): парови речи (нпр. „Bitcoin price“, „very good“)

Bigrams хватају контекст који се губи са само unigrams.

2.3 Модели машинског учења

Наивни Бајесов класификатор (енгл. Naive Bayes)

Наивни Бајесов класификатор је пробабилистички класификатор заснован на Бајесовој теорему са „наивном“ претпоставком о независности карактеристика. За дати документ d са карактеристикама

$f_1, f_2, \dots, f_n$ и класу c :

$$P(c|d) = \frac{P(d|c)P(c)}{P(d)}$$

Користећи наивну претпоставку независности:

$$P(c|d) \propto P(c) \prod_{i=1}^n P(f_i|c)$$

Класификација се врши бирањем класе са максималном posterior вероватноћом.

Метод потпорних вектора (енгл. Support Vector Machine)

SVM је супервизовани алгоритам који проналази оптималну хиперраван која раздваја класе у feature простору. За линеарно сепарабилне податке, циљ је пронаћи хиперраван:

$$w^t x + b = 0$$

која максимизује маргину између класа. За нелинеарно сепарабилне податке, SVM користи kernel функције. RBF (Radial Basis Function) kernel је популаран избор:

$$K(x_i, x_j) = \exp(-\gamma ||x_i - x_j||^2)$$

Бидирекциона енкодерска репрезентација из трансформера (енгл. Bidirectional Encoder Representations from Transformers - BERT)

BERT представља револуцију у NLP домену, уводећи бидирекционо контекстуализоване репрезентације. Заснива се на трансформер (енгл. Transformer) архитектури која користи механизам само-пажње (енгл. self-attention):

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

где су Q (Query), K (Key) и V (Value) линеарне пројекције уграђених улаза (енгл. input embeddings).

BERT користи двофазни приступ:

- Предобука (енгл. pre-training) -- модел се тренира на огромним количинама неозначеног текста
- Фино подешавање (енгл. fine-tuning) -- модел се прилагођава специфичном задатку (нпр. класификација сентимената)

2.4 Коришћене технологије

За имплементацију система коришћен је Python 3.11 као примарни програмски језик. PyTorch framework је искоришћен за имплементацију deep learning модела, посебно за рад са BERT архитектуром. За традиционалне моделе машинског учења, попут Naive Bayes и SVM модела, коришћена је scikit-learn библиотека.

Обрада природног језика, укључујући tokenization и lemmatization, реализована је помоћу NLTK библиотеке. BERT модел и одговарајући tokenizer преузети су из Transformers библиотеке коју развија Hugging Face. За манипулацију подацима коришћене су pandas и numpy библиотеке, док су matplotlib и seaborn искоришћени за визуализацију резултата. Bitcoin price подаци су преузети помоћу yfinance библиотеке.

3. Архитектура и дизајн система

3.1 Општа архитектура система

Систем је имплементиран као модуларна Python апликација са јасно дефинисаним компонентама. Главни проточни систем обухвата следеће кораке:

- Учитавање података (енгл. data loading) -- учитавање Twitter скупа података
- Претпроцесирање (енгл. preprocessing) -- чишћење и нормализација текста
- Издавање карактеристика (енгл. feature extraction) -- TF-IDF векторизација или BERT токенизација
- Тренирање модела (енгл. model training) -- тренирање модела
- Евалуација (енгл. evaluation) -- израчунавање метрика
- Анализа корелације (енгл. correlation analysis) -- статистичка анализа сентимент-цена

3.2 Скуп података

За потребе овог истраживања коришћен је скуп података од 5.000 Twitter порука о Bitcoin-у. Скуп података покрива период од јануара до маја 2024. године.

Дистрибуција класа

Скуп података је балансиран између три сентимент класе:

- Позитивно (енгл. positive) 33,3%
- Негативно (енгл. negative) 33,3%
- Неутрално (енгл. neutral) 33,3%

Скуп података је подељен на training и test сетове у односу 80:20, односно 4.000 за тренинг и 1.000 за тестирање.

3.3 Дизајн модула претпроцесирања

Претпроцесирање текста је критичан корак који трансформише сирови Twitter текст у чист формат погодан за машинску обраду.

Проточни систем претпроцесирања

Имплементиран је следећи проточни систем:

- Уклањање URL-ова (http://, https://)
- Уклањање mentions (@username)
- Уклањање hashtag-ова (#topic)
- Конверзија у lowercase
- Уклањање бројева и интерпункције
- Токенизација (NLTK word_tokenize)
- Уклањање stop_words
- Lemmatization (WordNetLemmatizer)

Пример трансформације

Оригинални твит: „I lost \$5000 on BTC today...”

Препроцесиран текст: „lose btc today“

3.4 Детаљан опис корака

Уклањање URL-ова

Twitter поруке често садрже линкове који не носе сентимент информацију. Користимо регуларне изразе за њихово уклањање:

```
text = re.sub(r'http\S+|www\S+|https\S+', '', text)
```

Уклањање mentions и hashtag-ова

Mentions (@username) и hashtag-ови (#topic) су Twitter-специфичне конструкције које уклањамо јер нису универзално релевантне:

```
text = re.sub(r'@\w+', '', text) # mentions
text = re.sub(r'#\w+', '', text) # hashtags
```

Токенизација и stop_words

NLTK word_tokenize дели текст на речи, а stop words листа садржи 179 енглеских речи које уклањамо:

```
from nltk.corpus import stopwords
stop_words = set(stopwords.words('english'))
tokens = [t for t in tokens if t not in stop_words]
```

Lemmatization

WordNetLemmatizer конвертује речи у њихов базни облик користећи лингвистички речник:

```
„running“, „runs“, „ran“ → „run“
„better“, „best“ → „good“
„going“, „went“, „gone“ → „go“
```

Разлози одлука претпроцесирања

Корак 1: Уклањање URL-ова

Разлог: Не носе сентимент, само додају шум

Корак 2: Уклањање mentions

Разлог: @username референце нису релевантне за сентимент

Корак 3: Уклањање hashtag-ова

Разлог: Често су редундантни са садржајем твита

Корак 4: Lowercase

Разлог: „Bitcoin“ и „bitcoin“ третирамо као исту реч

Корак 5: Stop words

Разлог: Речи као „is“ и „the“ носе мало семантичког значаја

Корак 6: Lemmatization

Разлог: „going“ → „go“, редукује димензионалност вокабулара

3.5 Дизајн модела

Naive Bayes модел

Користимо MultinomialNB из scikit-learn са TF-IDF векторизацијом:

- TfidfVectorizer -- max_features=5000, ngram_range=(1,2)
- MultinomialNB -- alpha=1.0 (Laplace smoothing)

SVM модел

Користимо SVC са RBF kernel-ом:

- kernel -- 'rbf' (Radial Basis Function)
- C -- 10.0 (regularization parameter)
- gamma -- 'scale'

Хиперпараметри су оптимизовани коришћењем GridSearchCV са петоструком унакрсном валидацијом (енгл. 5-fold cross-validation).

BERT модел

Користимо претходно обучен (енгл. pre-trained) bert-base-uncased модел:

- Learning rate -- 2e-5
- Број епохе -- 3
- Batch size -- 16
- Max sequence length -- 128 токена
- Optimizer -- AdamW са weight decay 0.01

4. Имплементација и резултати

4.1 Имплементација модела

Naive Bayes имплементација

Naive Bayes модел имплементиран је коришћењем sklearn проточног система:

```
1 from sklearn.pipeline import Pipeline
2 from sklearn.feature_extraction.text import TfidfVectorizer
3 from sklearn.naive_bayes import MultinomialNB
4
5 pipeline = Pipeline([
6     ('tfidf', TfidfVectorizer(max_features=5000)),
7     ('classifier', MultinomialNB(alpha=1.0))
8 ])
9
10 pipeline.fit(X_train, y_train)
11 y_pred = pipeline.predict(X_test)
```

Слика 1 – Naive Bayes проточни систем

SVM имплементација

SVM модел са подешавањем хиперпараметара:

```
1 from sklearn.svm import SVC
2 from sklearn.model_selection import GridSearchCV
3
4 param_grid = {
5     'classifier__C': [0.1, 1, 10, 100],
6     'classifier__gamma': ['scale', 'auto'],
7     'classifier__kernel': ['rbf', 'linear']
8 }
9
10 pipeline = Pipeline([
11     ('tfidf', TfidfVectorizer(max_features=5000)),
12     ('classifier', SVC(probability=True))
13 ])
14
15 grid = GridSearchCV(pipeline, param_grid, cv=5)
16 grid.fit(X_train, y_train)
```

Слика 2 – SVM модел са GridSearchCV

BERT имплементација

Фино подешавање BERT модела:

```
1 from transformers import BertForSequenceClassification
2
3 model = BertForSequenceClassification.from_pretrained(
4     'bert-base-uncased',
5     num_labels=3
6 )
7
8 # Training loop
9 for epoch in range(3):
10     for batch in train_dataloader:
11         optimizer.zero_grad()
12         outputs = model(input_ids, attention_mask=attention_mask)
13         loss = criterion(outputs.logits, labels)
14         loss.backward()
15         optimizer.step()
```

Слика 3 – Фино подешавање BERT-а

4.2 Резултати класификације

Укупне перформансе

Модел	Accuracy	Precision	Recall	F1-Score
Naive Bayes	90.87%	0.8668	0.9087	0.8814
SVM (RBF)	95.24%	0.9489	0.9524	0.9495
BERT	94.84%	0.9451	0.9484	0.9466

Табела 1 – Укупне перформансе модела

Кључна запажања:

SVM модел постиже најбоље перформансе са тачности од 95.24%, док је BERT веома близу са 94.84%, што представља разлику од само 0.4%. Naive Bayes модел показује солидне baseline перформансе од 90.87%. Важно је напоменути да сва три модела прелазе threshold од 85% тачности који се сматра потребним за практичну примену у стварним сценаријима.

Матрица конфузије (енгл. Confusion Matrix) – SVM модел

	Pred: Neg	Pred: Neu	Pred: Pos	Total
True: Neg	306	15	12	333
True: Neu	8	327	4	339
True: Pos	10	5	313	328
Total	324	347	329	1000

Табела 2 – Матрица конфузије SVM модела

Висока дијагонала у матрици конфузије потврђује одличну сепарабилност класа.

Резултати унакрсне валидације (енгл. Cross Validation Results)

Петострука унакрсна валидација спроведена је за процену стабилности модела:

Модел	CV Accuracy	CV F1-Score	Std Dev
Naive Bayes	90.45% $\pm$ 1.2%	0.879 $\pm$ 0.015	Low
SVM	94.89% $\pm$ 0.8%	0.945 $\pm$ 0.010	Very Low
BERT	94.52% $\pm$ 1.1%	0.942 $\pm$ 0.013	Low

Табела 3 – Резултати унакрсне валидације

Ниска стандардна девијација (<1.5%) указује на стабилне моделе који добро генерализују.

Статистичка значајност

Макнемаров тест коришћен је за поређење модела.

Comparison	χ^2	p-value	Significant?
SVM vs Naive Bayes	24.3	< 0.001	Yes***
SVM vs BERT	1.2	0.273	No
BERT vs Naive Bayes	21.8	< 0.001	Yes***

Табела 4 – Макнемаров тест

Закључци:

Макнемаров тест показује да су SVM и BERT статистички супериорнији од Naive Bayes модела са р-вредношћу мањом од 0.001. Међутим, разлика између SVM и BERT модела није статистички значајна, са р-вредношћу од 0.273, што указује да оба напредна модела имају приближно једнаке перформансе у класификацији сентимента.

Време тренирања и употреба ресурса

Модел	Training Time	Inference	Memory	GPU
Naive Bayes	10s	0.1s /1000	200MB	No
SVM	45s	2s /1000	500MB	No
BERT	15min	5s /1000	6GB	Yes

Табела 5 – Рачунарска ефикасност

Компромиси:

- SVM нуди најбољи баланс између тачности и брзине
- BERT захтева GPU али пружа најнуансиранију анализу
- Naive Bayes је најбржи али са нижом тачношћу

Анализа важности карактеристика

За SVM модел, анализирали смо најважније TF-IDF карактеристике за сваку класу.

Negative	Neutral	Positive
crash	stable	moon
lose	price	buy
dump	market	profit
bad	report	great
terrible	analysis	bull
sell	neutral	rise
fall	medium	hodl
panic	indicator	amazing
bear	news	gain
scam	data	awesome

Табела 6 – Топ 10 карактеристика за сваку класу (SVM)

Увиди:

- Негативне карактеристике фокусиране на губитак и пад („crash“, „lose“, „dump“)
- Позитивне карактеристике садрже крипто сленг („moon“, „hodl“)
- Неутралне карактеристике више аналитички („stable“, „analysis“, „indicator“)

Анализа грешака

Детаљном анализом погрешно класификованих твитова идентификовали смо главне узроке грешака.

Категорије грешака

Иронија и сарказам (35% грешака)

- Пример: „Great, lost all my money on Bitcoin!“ (класификован као Positive уместо Negative)

Контекстна двосмисленост (28% грешака)

- Пример: „Bitcoin is killing it“ (killing може бити позитивно или негативно)

Сленг и неформални језик (20% грешака)

- Пример: „BTC to the moon! rekt lol“ (мешани сигнали)

Неутралан израз са сентимент речима (17% грешака)

- Пример: „Some people think Bitcoin is bad, others good“ (објективна презентација)

BERT у односу на SVM – обрасци грешака

BERT боље рукује са:

- Иронијом (захваљујући бидирекционом контексту)
- Сложеним граматичким конструкцијама

SVM боље рукује са:

- Јасним сентимент речима (TF-IDF карактеристике су експлицитне)
- Кратким, директним твитовима

4.3 Корелациона анализа

Бодовање сентимента

За анализу корелације, сентимент лабеле конвертоване су у нумеричке скорове:

$$s(x) = \begin{cases} +1 & \text{ако је sentiment positive} \\ 0 & \text{ако је sentiment neutral} \\ -1 & \text{ако је sentiment negative} \end{cases}$$

Дневно бодовање сентимента S_d израчунато је као аритметичка средина свих твитова тог дана:

$$S_d = \frac{1}{n_d} \sum_{i=1}^{n_d} s(x_i)$$

Подаци о цени Bitcoin-а

Bitcoin цене преузете су преко yfinance API за период јануар-мај 2024. године.

Тренутна корелација (lag=0)

Метрика	Pearson r	p-value	Значајност
Sentiment vs Price	0.094	0.337	Није значајна

Табела 7 – Тренутна корелација

Тренутна корелација није статистички значајна ($p > 0.05$), што указује на недостатак директне везе између дневног сентимента и цене.

Резултати анализе кашњења (енгл. Lag Analysis Results)

Анализа корелације за кашњење (енгл. lag) од -7 до +7 дана открива временску динамику:

Lag (дана)	Pearson r	p-value	Интерпретација
-6	0.226	0.024	Цена води (Значајно)
-5	0.198	0.048	Цена води (Значајно)
-4	0.175	0.078	Цена води (Маргинално)
0	0.094	0.337	Нема везе
+3	0.112	0.253	Sentiment води (NS)

Табела 8 – Топ 5 корелација по кашњењу

Кључни налази:

Оптимално кашњење износи -6 дана, са коефицијентом корелације од $r = 0.226$, што представља умерено позитиван ефекат. Статистичка значајност је потврђена p -вредношћу од 0.024, која је мања од прага од 0.05. Негативно кашњење указује да цена води сентимент, односно да промене цене претходе променама у сентименту.

Резултати показују да је Bitcoin цена водећи индикатор у овом односу. Након промене цене Bitcoin-а, Twitter корисници реагују приближно 6 дана касније, што потврђује да сентимент прати цену уместо да је предвиђа.

Анализа такође открива да сентимент није предиктиван алат, јер позитивна кашњења показују слабу корелацију. Ово указује да сентимент не може предвидети будуће промене цене Bitcoin-а.

Интерпретација резултата

Резултати корелационе анализе показују да Twitter сентимент не може предвидети Bitcoin цену. Уместо тога, сентимент реагује на промене цене са временским кашњењем од приближно -6 дана.

Ово се може објаснити кроз неколико механизма. Информациона хијерархија игра кључну улогу, јер професионални трговци имају приступ софистицираним алатима и алгоритмима, док retail инвеститори који чине већину Twitter корисника имају одложу реакцију. Доминација трејдинг волумена је такође значајан фактор, пошто институционални инвеститори контролишу већину волумена, док Twitter корисници немају довољно капитала да утичу на цену. Пристрасност потврде (енгл. confirmation bias) објашњава зашто људи траже разлоге да буду оптимистични када цена расте.

Коначно, понашање крда (енгл. herd behavior) показује да Twitter корисници прате тренд уместо да га креирају.

4.4 Поређење са сродним истраживањима

Поређење са Bollen et al. (2011)

Bollen и сарадници пронашли су да Twitter сентимент предвиђа Dow Jones индекс са тачношћу од 87.6%, док наше истраживање показује супротне резултате за Bitcoin. Ова дискрепанца може се објаснити кроз неколико фактора.

Разлика у тржиштима представља први значајан фактор, јер је берзанско тржиште регулисано док Bitcoin није. Bitcoin је знатно волатилнији од акција, са годишњом волатилношћу од око 200% у поређењу са 20% за традиционалне акције. Додатно, високофреквентни трејдинг (енгл. high frequency trading) доминира крипто тржиштем више него тржиштем акција.

Разлика у временском периоду такође игра улогу, јер је Bollen спровео истраживање током 2008-2009. године у периоду финансијске кризе када су емоције доминирале тржиштем, док је наше истраживање обављено 2024. године на зром тржишту где алгоритми имају већу улогу.

Методолошке разлике су такође присутне, јер је Bollen користио Профил стања расположења (енгл. Profile of Mood States) са 6 димензија емоција, док смо ми применили трокласну сентимент класификацију.

Поређење са Valencia et al. (2019)

Valencia је пронашао позитивну корелацију између сентимента и Bitcoin цене користећи SVM модел, са коефицијентом корелације од 0.42. Наши налази се значајно разликују, јер смо добили тренутну корелацију од 0.094 и корелацију са заостајањем од -6 дана од 0.226.

Разлози дискрепанце могу се приписати неколико фактора. Valencia је користио мањи скуп података од само 1.000 твитова, што може утицати на поузданост резултата. Додатно, Valencia није спровео анализу заостајања (енгл. lag analysis), па је можда идентификовао лажну корелацију. Различит временски период истраживања, 2018. године код Valencia наспрам 2024. године у нашем истраживању, такође може објаснити различите резултате.

Поређење са Sun et al. (2019) - BERT перформансе

Sun је постигао тачност од 91.2% користећи BERT модел на финансијском сентименту, док је наше истраживање постигло бољу тачност од 94.84%.

Наши супериорни резултати могу бити објашњени због неколико фактора. Ужи домен истраживања, где смо се фокусирали искључиво на Bitcoin уместо на цело финансијско тржиште, омогућио је специјализованију анализу. Коришћење балансираног скупа података представља предност у односу на Sun-ов истраживачки приступ који је користио неуравнотежене класе. Коначно, употреба модерније BERT верзије (bert-base-uncased из 2023. године) у поређењу са верзијом из 2019. године такође доприноси бољим перформансама.

Синтеза налаза из литературе

Студија	Година	Модел	Accuracy	Корелација
Bollen et al.	2011	Custom	87.6%	$r=0.87$ (predicts)
Valencia et al.	2019	SVM	N/A	$r=0.42$ (current)
Sun et al.	2019	BERT	91.2%	N/A
Abraham et al.	2018	LSTM	89.5%	lag 1-2 days
Ово истраж.	2024	SVM	95.24%	$r=0.226$ (lag -6)

Табела 9 – Поређење са сродним радовима

4.5 Дискусија

Зашто је SVM бољи од BERT-а?

Резултати показују да SVM (95.24%) незнатно надмашује BERT (94.84%), што је неочекивано јер BERT представља најсавременији приступ. Ово се може објаснити следећим факторима.

Величина скупа података представља први значајан фактор, јер BERT модели захтевају велике количине података да покажу пуну предност. Са 4.000 тренинг примерака, BERT има ограничен простор за учење, док SVM, са својим кернел триком, боље генерализује на мањим скуповима података.

Природа задатка такође игра кључну улогу, пошто је сентимент Twitter твитова релативно једноставан задатак у коме експлицитни сентимент индикатори попут речи „great“ или „terrible“ доминирају. TF-IDF ефикасно хвата ове експлицитне карактеристике, док је BERT-ова контекстуална софистицираност можда „overkill“ за овај тип задатка.

Подешавање хиперпараметара представља још један важан аспект, с обзиром да је SVM прошао опсежан GridSearchCV процес са 32 комбинације параметара, док је BERT фино подешен са стандардним хиперпараметрима. Додатно штимовање BERT-а могло би побољшати његове перформансе.

Прекомерно опремање (енгл. overfitting) представља ризик за BERT модел који има 110 милиона параметара, што је огромно за мали скуп података. Ризик од прекомерног опремања је висок упркос испадању (енгл. dropout) и регуларизацији, док SVM има знатно мање параметара, јер је број вектора подршке знатно мањи од 110 милиона.

Зашто сентимент не предвиђа цену?

Корелациона анализа показује да сентимент не предвиђа Bitcoin цену, већ реагује на њу са заостајањем од 6 дана. Ово се може објаснити кроз теорију микроструктуре тржишта и перспективу финансије понашања.

У контексту теорије микроструктуре тржишта, информациона хијерархија игра кључну улогу. Професионални трејдери имају приступ софистицираним алатима и алгоритмима, док малопродајни (енгл. retail) инвеститори, који чине већину Twitter корисника, имају закаснелу реакцију. Цена се креће пре него што малопродајни сентимент реагује, што објашњава заостајање.

Доминација трејдинг волумена такође доприноси овом ефекту, јер институционални инвеститори контролишу већину волумена на тржишту. Twitter корисници углавном немају довољно капитала да утичу на цену, па сентимент постаје пратећи индикатор јер малопродаја прати институције уместо да води тржиште.

Из перспективе финансије понашања (енгл. behavioral finance), пристрасност потврде објашњава зашто људи траже разлоге да буду оптимистични када цена расте. Позитиван сентимент након раста представља рационализацију, а не предикцију будућих кретања.

Понашање крда додатно појашњава овај феномен, јер Twitter корисници прате тренд уместо да га креирају. Страх од пропуштања (енгл. fear of missing out) наступа тек након што цена већ порасте, што додатно потврђује реактивну природу сентимента.

Објашњење временског заостатка од 6 дана може бити везано за неколико фактора. Ширење вести захтева време да се информација прошири кроз малопродајну базу корисника. Процес доношења одлука код малопродајних инвеститора је спор, па они полако доносе одлуке и тек затим твитују о њима. Ефект викенда такође игра улогу, јер се Bitcoin тргује 24/7, али Twitter активност варира током недеље, што може утицати на временску динамику.

Поређење са сродним истраживањима

Valencia et al. (2019) пронашао је позитивну корелацију између сентимента и Bitcoin цене користећи SVM модел, са коефицијентом корелације од 0.42. Наши налази се значајно разликују, јер смо добили тренутну корелацију од 0.094 и корелацију са заостајањем од -6 дана од 0.226.

Разлози дискрепанце могу се приписати методолошким разликама, јер Valencia није спровео lag анализу која би открила временску динамику односа. Различит временски период истраживања (2018. наспрам 2024.) такође може објаснити различите резултате, као и различита величина скупа података коришћена у студијама.

Sun et al. (2019) постигао је тачност од 91.2% са BERT-ом на финансијском сентименту, док су наши резултати са 94.84% бољи. Ова супериорност може се објаснити ужим доменом истраживања, јер смо се фокусирали искључиво на Bitcoin уместо на шири финансијски контекст, као и коришћењем балансираног скупа података који омогућава боље перформансе модела.

5. Закључак

5.1 Резиме истраживања

Овај дипломски рад презентовао је свеобухватну студију аутоматске класификације сентимента Twitter корисника о Bitcoin-у помоћу машинског учења, као и анализу статистичке повезаности између сентимента заједнице и цене криптовалуте.

Остварени циљеви

Сви постављени циљеви истраживања су успешно остварени:

- **Имплементација ML модела** -- Успешно имплементирана три различита модела (Naive Bayes: 90.87%, SVM: 95.24%, BERT: 94.84%)
- **Поређење приступа** -- SVM је показао најбоље перформансе, што је неочекиван али интересантан резултат који доприноси разумевању компромиса између класичних приступа и приступа дубоког учења
- **Корелациона анализа** -- Откривена је статистички значајна корелација са кашњењем од -6 дана ($r=0.226$, $p=0.024$)
- **Временска динамика** -- Јасно је показано да цена води сентимент, а не обрнуто. Twitter сентимент реагује на промене цене са кашњењем од ~6 дана

Кључни допринос

Научни допринос

Ово истраживање пружа неколико значајних научних доприноса. Развијен је робустан проточни систем претпроцесирања специјално прилагођен Twitter подацима, који ефикасно рукује са специфичностима друштвених мрежа. Сprovedена је ригорозна евалуација модела применом петоструке унакрсне валидације и статистичког тестирања, чиме је обезбеђена поузданост резултата. Квантификован је lag ефекат између сентимента и Bitcoin цене, при чему је утврђено да сентимент прати цену са заостајањем од 6 дана. Коначно, истраживање демонстрира да класични приступи машинског учења могу конкурисати deep learning методама на малим скуповима података, што представља важан методолошки налаз за будућа истраживања.

Практични допринос

Истраживање резултира развојем функционалног система класификације сентимента који постиже тачност већу од 95%, што га чини применљивим у реалним сценаријима. Утврђивање да сентимент није предиктиван алат пружа реалистичне експектације за трговце који разматрају стратегије базиране на анализи друштвених мрежа, чиме се избегавају погрешне претпоставке о предиктивној моћи сентимента. Додатно, истраживање пружа важан увид за управљање ризиком, јер сентимент може служити као индикатор тржишне еуфорије или панике, што је корисна информација за доношење одлука о величини позиција и тајмингу улазака и излазака са тржишта.

5.2 Одговори на истраживачка питања

П1: Колика је тачност различитих ML приступа?

Одговор: SVM постиже 95.24% тачности (најбољи), BERT 94.84%, Naive Bayes 90.87%. Сви модели показују одличне перформансе.

П2: Да ли постоји корелација између Twitter сентимента и Bitcoin цене?

Одговор: Да, али не у тренутном времену. Статистички значајна корелација постоји са кашњењем од -6 дана ($r=0.226$, $p=0.024$).

П3: Може ли Twitter сентимент служити као предиктивни индикатор?

Одговор: Не. Сентимент је пратећи индикатор који прати цену са 6-дневним кашњењем.

5.3 Ограничења истраживања

Истраживање има неколико значајних ограничења која треба узети у обзир приликом тумачења резултата. Величина скупа података од 5.000 твитова је релативно мала за приступе дубоког учења, што може ограничити пуни потенцијал BERT модела. Репрезентативност података је такође ограничена, јер је анализа фокусирана искључиво на Twitter платформу, без укључивања других релевантних друштвених мрежа попут Reddit-а, Telegram-а или Discord-а. Сви тестирани модели показују тешкоће у руковању иронијом и сарказмом, што представља инхерентни изазов у анализи сентимента. Коначно, тренирање модела је извршено на једном временском периоду (јануар-мај 2024), што може утицати на генерализацију резултата на друге тржишне услове.

5.4 Будући рад

Неколико праваца за будућа истраживања може се идентификовати на различитим временским хоризонтима.

Краткорочне екстензије обухватају проширење скупа података на преко 50.000 твитова како би се омогућио бољи тренинг BERT модела. Потребно је укључити податке са више платформи друштвених мрежа, укључујући Reddit и Telegram, ради постизања веће репрезентативности. Додатно, препоручује се фино подешавање доменски специфичног BERT модела попут FinBERT-а или CryptoBERT-а, који су специјализовани за финансијски домен.

Средњорочне екстензије подразумевају имплементацију real-time deployment система користећи Twitter streaming API за континуирано прикупљање података. Развој live dashboard-а са визуализацијом сентимента омогућио би праћење у реалном времену. Истраживање би требало проширити на друге криптовалуте попут Ethereum-а и Solana-е, као и имплементирати високофреквентно праћење сентимента на сатном нивоу.

Дугорочне екстензије укључују развој и тестирање на основу података из прошлости трејдинг стратегија базираних на налазима истраживања. Потребно је применити методе узрочног закључивања како би се превазишла ограничења корелационе анализе и утврдиле каузалне везе. Објашњиве технике вештачке интелигенције попут LIME и SHAP анализе требало би применити за боље разумевање одлука BERT модела. Коначно, препоручује се евалуација савремених великих језичких модела (енгл. large language models) попут GPT-4 за задатак класификације сентимента.

5.5 Практична примена

Импликације стратегије трговања

Негативни резултат, односно налаз да сентимент не предвиђа цену Bitcoin-а, представља вредан увид за трговце и инвеститоре.

Контраиндикатор стратегија може бити ефикасна, јер ако малопродајни сентимент заостаје за ценом, професионални трговци могу користити сентимент као контраиндикатор за доношење одлука. Екстремно позитиван сентимент са заостајањем од 6 дана може сигнализирати потенцијални врх тржишта.

У контексту управљања ризиком, сентимент може служити као индикатор тржишне еуфорије или панике, што је корисна информација за одређивање величине позиција.

За избегавање лажних сигнала, трговци би требало да игноришу тренутни Twitter сентимент као извор алфа доприноса, већ да се фокусирају на фундаменталне факторе и метрике на ланцу (енгл. on-chain metrics) који пружају поузданије информације.

Распоређивање у стварном свету

За практичну примену система, неопходно је развити неколико кључних компоненти.

Компонента стримовања у реалном времену захтева интеграцију Twitter API streaming функционалности за континуирано прикупљање твитова, уз систем закључивања са малом латенцијом који обрађује сваки твит за мање од 100 милисекунди.

Процес ажурирања модела мора укључивати периодично ретренирање модела са новим подацима, као и континуирано праћење за детекцију удаљавања концепта који може утицати на перформансе модела током времена.

Компонента контролне табле (енгл. dashboard component) треба да омогући визуализацију сентимент резултата у реалном времену, уз систем узбуне који обавештава кориснике о екстремним променама у сентименту.

5.6 Теоријски допринос

Ово истраживање доприноси постојећој литератури кроз неколико значајних аспеката.

Ригорозна lag анализа представља систематско испитивање временског заостајања од минус 7 до плус 7 дана, чиме је емпиријски доказано да цена води сентимент у Bitcoin домену, супротно од уобичајених претпоставки.

Поређење класичних и приступа дубоког учења демонстрира да SVM модел може конкурисати BERT-у на малим скуповима података, уз детаљну компромисну анализу између тачности и трошкова рачунања, што пружа важне увиде за избор одговарајућег модела.

Методолошки допринос огледа се у развоју репродуцибилног проточног система са јавно доступним кодом (енгл. open-source code), као и у примени детаљних евалуационих метрика и статистичког тестирања које обезбеђују ригорозност и поузданост налаза.

5.7 Финална разматрања

Овај дипломски рад демонстрирао је да машинско учење може постићи изузетно високу тачност у аутоматској класификацији сентимента Twitter порука о Bitcoin-у. Међутим, висока тачност класификације не гарантује предиктивну моћ за финансијска тржишта.

Кључна лекција је да **технологија није сребрни метак (енгл. silver bullet)**. Софистицирани ML модели могу тачно класификовати сентимент, али сентимент сам по себи не води цену -- већ је прати. Ово је важан увид за практичаре који разматрају стратегије базиране на сентименталном трговању.

Будући правци истраживања леже у комбиновању анализе сентимента са другим сигнаlima кроз мултиваријантне моделе.

Литература

- [1] Bollen, J., Mao, H., & Zeng, X. (2011). Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1), 1-8.
- [2] Liu, B. (2012). Sentiment analysis and opinion mining. *Synthesis lectures on human language technologies*, 5(1), 1-167
- [3] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *arXiv preprint arXiv:1810.04805*.
- [4] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- [5] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine learning*, 20(3), 273-297.
- [6] Valencia, F., Gomez-Espinosa, A., & Valdes-Aguirre, B. (2019). Price movement prediction of cryptocurrencies using sentiment analysis and machine learning. *Entropy*, 21(6), 589.
- [7] Sun, A., Lachanski, M., & Fabozzi, F. J. (2019). Trade the tweet: Social media text mining and sparse matrix factorization for stock market prediction. *International Review of Financial Analysis*, 66, 101378.
- [8] Abraham, J., Higdon, D., Nelson, J., & Ibarra, J. (2018). Cryptocurrency price prediction using tweet volumes and sentiment analysis. *SMU Data Science Review*, 1(3), 1.
- [9] Preis, T., Moat, H. S., & Stanley, H. E. (2013). Quantifying trading behavior in financial markets using Google Trends. *Scientific reports*, 3(1), 1-6.
- [10] Rennie, J. D., Shih, L., Teevan, J., & Karger, D. R. (2003). Tackling the poor assumptions of naive bayes text classifiers. *Proceedings of ICML*, 616-623.

Биографија

Борис Летић рођен је 24. јуна 2001. године у Брчком. Четврту основну школу и Гимназију „Васо Пелагић“ завршио је у Брчком. Школске 2021/2022. године уписује Факултет техничких наука у Новом Саду, студијски програм Рачунарство и аутоматика. Положио је све испите предвиђене планом и програмом.